


PREDIÇÃO DE HIPERTIREOIDISMO COM MACHINE LEARNING

PROJETO FINAL - FORMAÇÃO
CIENTISTA DE DADOS (EBAC)

Formação Cientista de Dados

Desenvolvimento de modelo preditivo para identificação de hipertireoidismo a partir de dados clínicos e laboratoriais.



Por que esse problema é importante?

- O hipertireoidismo pode causar complicações graves quando não diagnosticado precocemente.
- Os sintomas são frequentemente confundidos com outras condições.
- O diagnóstico depende da análise conjunta de diversos exames.

Objetivo: Desenvolver um modelo capaz de identificar pacientes com hipertireoidismo com alta confiabilidade.



EBAC



Dados Utilizados

Coleta e Tratamento

Fonte: Dataset fornecido pela EBAC

Características:

- Aproximadamente 4.500 registros
- Dados clínicos e laboratoriais
- Variáveis demográficas
- Exames hormonais

Target: Saudável / Hipertireoidismo

Análise Exploratória

Investigação estatística das variáveis clínicas como TSH, T3 e T4. Identificação de correlações, distribuições e padrões relevantes para a predição de hipertireoidismo através de visualizações.

Modelagem Preditiva

Aplicação de algoritmos de Machine Learning incluindo Random Forest, XGBoost e Regressão Logística. Validação cruzada e otimização de hiperparâmetros para maximizar a acurácia do modelo.

Principais Grupos de Atributos

Exames Hormonais

TSH
T3
TT4
T4U
FTI
TBG

Histórico Clínico

sick
goitre
tumor
psych


Tratamentos

on_thyroxine
lithium
I131 treatment

Dados Demográficos

age
sex


Pipeline do Projeto




O que os dados mostraram?

- Existência de valores ausentes
- Classes desbalanceadas
- Exames hormonais apresentaram forte relação com o diagnóstico
- TSH apresentou comportamento distinto entre pacientes saudáveis e doentes

Mediana de tsh por binaryclass



Estratégia de Modelagem



Técnicas utilizadas:

- Cross Validation
- GridSearchCV
- Otimização baseada em Recall


Priorizamos minimizar falsos negativos, reduzindo a chance de deixar pacientes doentes sem diagnóstico.

Desempenho dos Modelos

Principais resultados:

- Accuracy próxima de 99%
- Recall de aproximadamente 99%
- Excelente equilíbrio entre precisão e sensibilidade

O modelo otimizado apresentou desempenho superior e foi selecionado para as análises finais.




MATRIZ DE CONFUSÃO

RESULTADOS:

- 692 PACIENTES COM HIPERTIREOIDISMO IDENTIFICADOS CORRETAMENTE
- APENAS 5 FALSOS NEGATIVOS
- APENAS 1 FALSO POSITIVO

O MODELO DEMONSTROU ELEVADA CAPACIDADE DE IDENTIFICAR PACIENTES DOENTES.



QUAIS VARIÁVEIS MAIS INFLUENCIAM O DIAGNÓSTICO?


PRINCIPAIS VARIÁVEIS:

1. TSH
2. FTI
3. TT4
4. T4U

CONCLUSÃO:

OS EXAMES HORMONAIS FORAM OS PRINCIPAIS RESPONSÁVEIS PELAS DECISÕES DO MODELO.

Top 15 Fatores que Mais Impactam a Satisfação do Passageiro



CONCLUSÕES E PRÓXIMOS PASSOS

PRINCIPAIS CONCLUSÕES:

- ✓ MODELO COM DESEMPENHO SUPERIOR A 99%
- ✓ BAIXA OCORRÊNCIA DE FALSOS DIAGNÓSTICOS
- ✓ TSH IDENTIFICADO COMO PRINCIPAL MARCADOR
- ✓ POTENCIAL PARA APOIAR PROCESSOS DE TRIAGEM

PRÓXIMOS PASSOS:

- TESTAR NOVOS ALGORITMOS
- DESENVOLVER API PARA USO EM PRODUÇÃO
- VALIDAR COM DADOS CLÍNICOS REAIS

99%
Recall

99%
Accuracy

TSH
Principal
Feature

